

Матричные факторизации

RecSys

lecturer: Mollaev D. E.
Sber AI Lab

План лекции:

- Recap
- PCA: связь с матричными разложениями
- SVD и SVD compact
- Truncated SVD
- Funk SVD
- Интерпретация SVD
- ALS, IALS

План лекции:

- Recap
- PCA: связь с матричными разложениями
- SVD и SVD compact
- Truncated SVD
- Funk SVD
- Интерпретация SVD
- ALS, IALS

Виды постановок задачи рекомендаций

Наша цель — рекомендовать пользователю такие айтемы, которые сделают его счастливым.


Обычно под «счастьем» упрощённо понимают то, понравилась ли рекомендация в текущий момент. Иногда — ещё проще: нравится ли сам айтем или какую оценку пользователь ему поставит.

Пользователя можно моделировать по-разному:

- Как неупорядоченное множество айтемов, с которыми он взаимодействовал
- Как неупорядоченное множество айтемов с привязанными оценками
- Как последовательность айтемов с оценками
- Как последовательность взаимодействий с учётом контекста

Recap: Item2item, User2user

User2User



2		2	4	5	
5		4			1
		5		2	
	1		5		4
		4			2
4	5		1		



Item2Item



2		2	4	5	
5		4			1
		5		2	
	1		5		4
		4			2
4	5		1		



Recap: Item2item, User2user

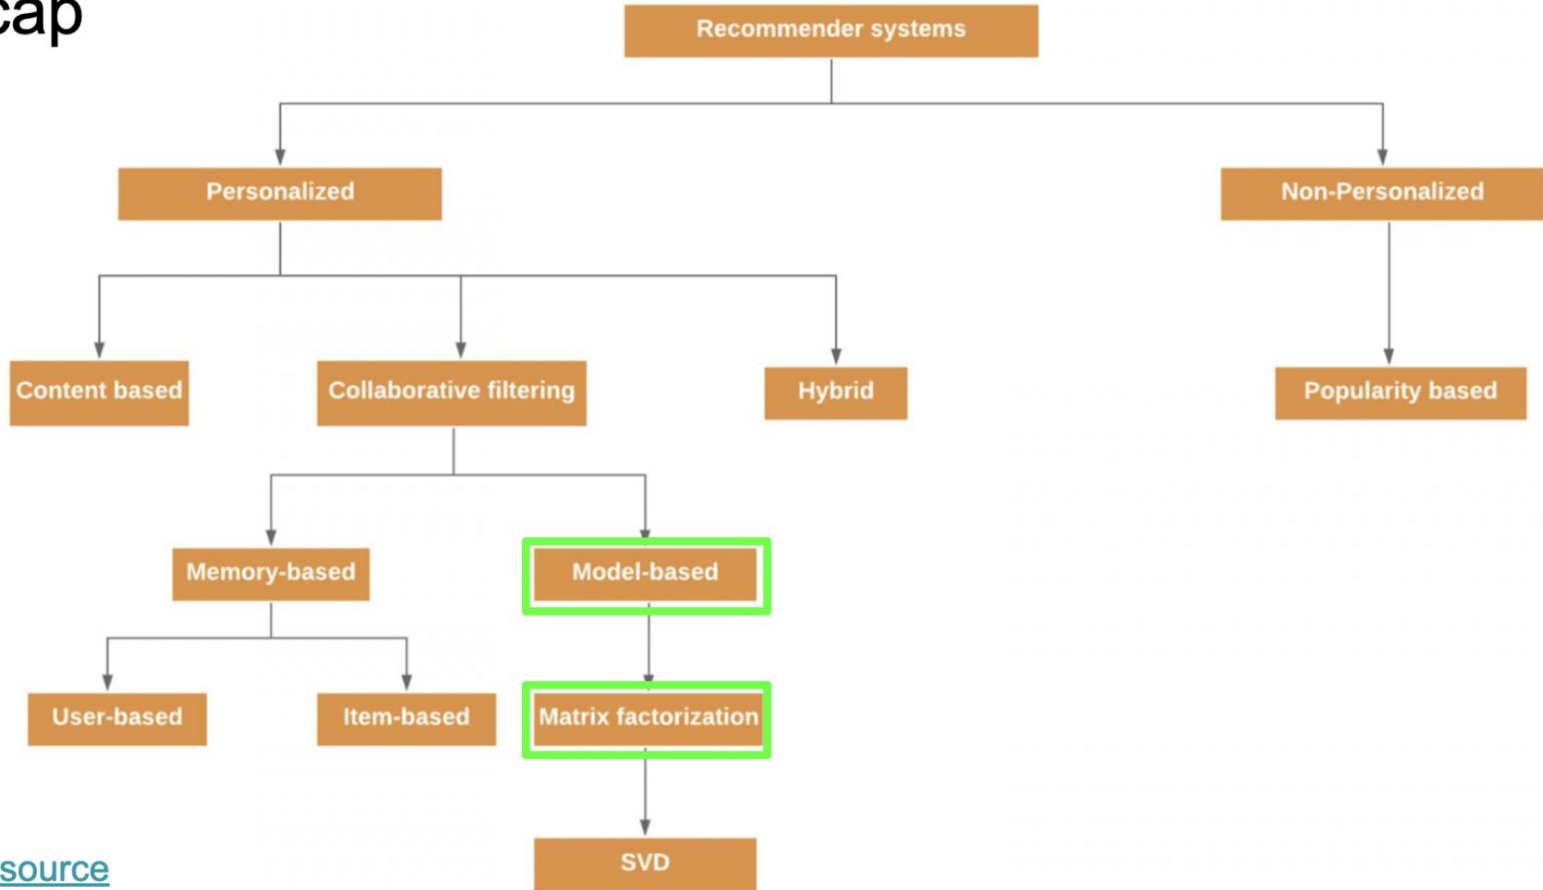
- **Зависимость от количества оценок**

Выбор между методами сильно зависит от числа оценок на пользователя и на объект: чем больше оценок, тем надёжнее определяется схожесть между ними.

- **Возможность периодического обновления**

При большом количестве оценок добавление нескольких новых практически не влияет на результат, поэтому схожести можно пересчитывать с определённой периодичностью, а не в реальном времени..

Recap





[Image source](#)

План лекции:


- Ресар
- PCA: связь с матричными разложениями
- SVD и SVD compact
- Truncated SVD
- Funk SVD
- Интерпретация SVD
- ALS, IALS

РСА: связь с матричными разложениями


$$\sum_i \text{dist}(x_i, L_k) \rightarrow \min$$



РСА: связь с матричными разложениями



$$r_{ij} = \bar{u}_i^T \bar{v}_j + b_i$$




План лекции:

- Recap
- PCA: связь с матричными разложениями
- SVD и SVD compact
- Truncated SVD
- Funk SVD
- Интерпретация SVD
- ALS, IALS

SVD (Singular value decomposition)


$$\begin{aligned}R &= U\Sigma V^T \\ UU^T &= U^T U = I_M \\ VV^T &= V^T V = I_N\end{aligned}$$



$$r_{ij} = \bar{u}_i^T \Sigma \bar{v}_j$$

SVD compact

$$R = U\Sigma V^T$$
$$l = \text{rank}\{R\}$$
$$U^T U = V^T V = I_l$$




$$r_{ij} = \bar{u}_i^T \Sigma \bar{v}_j$$

План лекции:

- Recap
- PCA: связь с матричными разложениями
- SVD и SVD compact
- Truncated SVD
- Funk SVD
- Интерпретация SVD
- ALS, IALS

Truncated SVD

$$\begin{aligned} R &\approx U \Sigma V^T \\ k &\ll l = \text{rank}\{R\} \\ U^T U &= V^T V = I_k \end{aligned}$$



$$r_{ij} = \bar{u}_i^T \Sigma \bar{v}_j$$

Truncated SVD: оптимизация

$$R \approx U \Sigma V^T$$
$$U^T U = V^T V = I_k$$

$$\min_{\substack{U, V, \Sigma \\ U^T U = V^T V = I_k \\ \sigma_{ij} = 0, i \neq j \\ \sigma_{ii} > \sigma_{jj}, i < j}} \sum_{\forall i, j} (r_{ij} - u_i^T \Sigma v_j)^2 \quad \Leftrightarrow \quad \min_{X, Y} \sum_{\forall i, j} (r_{ij} - x_i^T y_j)^2$$

Truncated SVD: оптимизация

$$R \approx U \Sigma V^T$$
$$U^T U = V^T V = I_k$$

$$U \Sigma V^T = X Y^T$$
$$X^T X \neq I_k, Y^T Y \neq I_k$$

$$\min_{\substack{U, V, \Sigma \\ U^T U = V^T V = I_k \\ \sigma_{ij} = 0, i \neq j \\ \sigma_{ii} > \sigma_{jj}, i < j}} \sum_{\forall i, j} (r_{ij} - u_i^T \Sigma v_j)^2$$

\Leftrightarrow

$$\min_{X, Y} \sum_{\forall i, j} (r_{ij} - x_i^T y_j)^2$$

Truncated SVD: оптимизация

$$R \approx U \Sigma V^T$$

$$U^T U = V^T V = I_k$$

$$U \Sigma V^T = X Y^T$$

$$X^T X \neq I_k, Y^T Y \neq I_k$$


$$\min_{\substack{U, V, \Sigma \\ U^T U = V^T V = I_k \\ \sigma_{ij} = 0, i \neq j \\ \sigma_{ii} > \sigma_{jj}, i < j}} \sum_{\forall i, j} (r_{ij} - u_i^T \Sigma v_j)^2 \quad \Leftrightarrow \quad \min_{X, Y} \sum_{\forall i, j} (r_{ij} - x_i^T y_j)^2$$

$$\min_{X, Y} \sum_{\forall i, j} (r_{ij} - x_i^T y_j)^2 + \lambda \sum_i \|x_i\|^2 C_i + \lambda \sum_j \|y_j\|^2 C_j$$

$$C_i = \frac{|\{j | r_{ij} > 0\}|^\alpha |\{i\}|}{\sum_i |\{j | r_{ij} > 0\}|^\alpha}$$

Truncated SVD: оптимизация

$$\min_{X,Y} \sum_{\forall i,j} (r_{ij} - x_i^T y_j)^2 + \lambda \sum_i \|x_i\|^2 C_i + \lambda \sum_j \|y_j\|^2 C_j$$

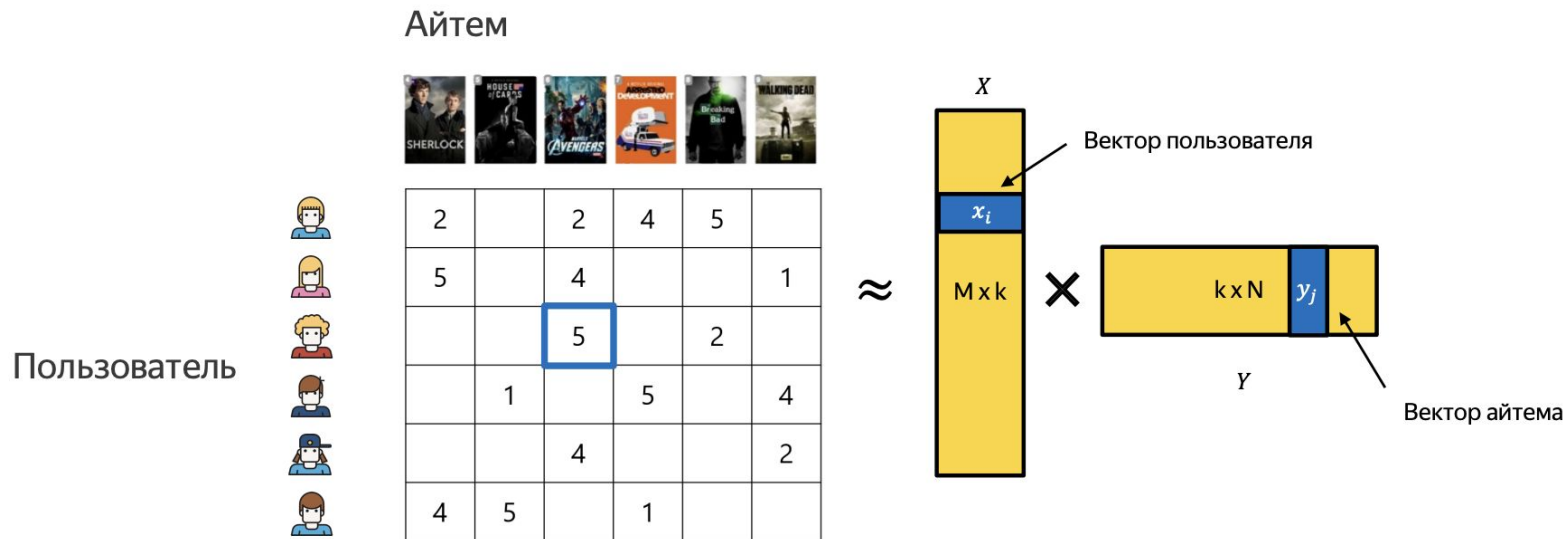


$$r_{i,j} = x_i^T y_j$$

План лекции:

- Recap
- PCA: связь с матричными разложениями
- SVD и SVD compact
- Truncated SVD
- Funk SVD
- Интерпретация SVD
- ALS, IALS

Funk SVD



$$\min_{X,Y} \sum_{(i,j) \in R} (r_{ij} - x_i^T y_j)^2 + \lambda \sum_i \|x_i\|^2 C_i + \lambda \sum_j \|y_j\|^2 C_j$$

План лекции:

- Recap
- PCA: связь с матричными разложениями
- SVD и SVD compact
- Truncated SVD
- Funk SVD
- Интерпретация SVD
- ALS, IALS

Интерпретация SVD



Интерпретация SVD



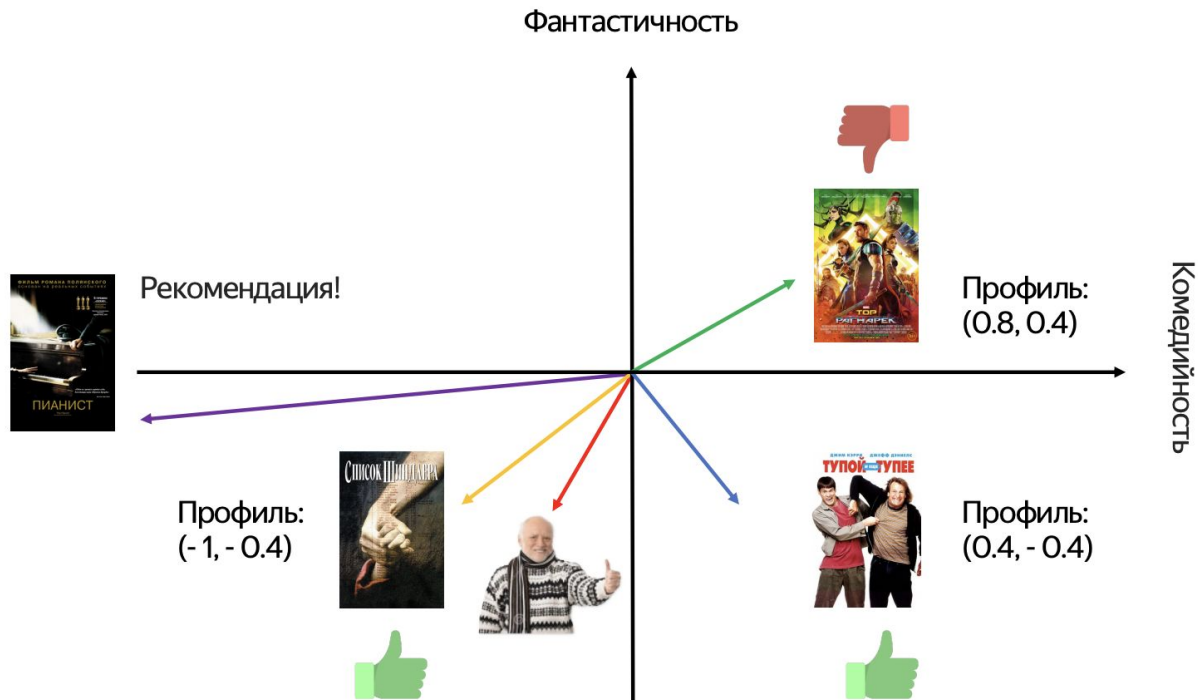
Интерпретация SVD



Интерпретация SVD



Интерпретация SVD



Итоги SVD

- В отличие от коллаборативной фильтрации (CF), матричные факторизации (MF) не используют явные сходства между товарами.
- MF стремятся представить пользователей и товары через небольшое число скрытых признаков, объясняющих выставленные оценки.
- Эти признаки часто сложно интерпретировать — как минимум, векторы пользователей и товаров определены лишь с точностью до поворота в пространстве.

План лекции:

- Recap
- PCA: связь с матричными разложениями
- SVD и SVD compact
- Truncated SVD
- Funk SVD
- Интерпретация SVD
- ALS, IALS

ALS (Alternating Least Squares)

$$\min_{X,Y} \sum_{(i,j) \in R} (r_{ij} - x_i^T y_j)^2 + \lambda \sum_i \|x_i\|^2 C_i + \lambda \sum_j \|y_j\|^2 C_j$$

Инициализируем X и Y случайными значениями.

В цикле:

- Фиксируем матрицу X (пользователей)
- Находим оптимальную матрицу Y (решаем гребневую регрессию для каждого товара)



- И наоборот

ALS (Alternating Least Squares)

$$\begin{aligned}
 & \operatorname{argmin}_{x_i} \sum_{(i,j) \in R} (r_{ij} - x_i^T y_j)^2 + \lambda \sum_i \|x_i\|^2 C_i + \lambda \sum_j \|y_j\|^2 C_j = \\
 & \operatorname{argmin}_{x_i} \sum_{(i,j) \in R} r_{ij}^2 - 2 \sum_{(i,j) \in R} r_{ij} x_i^T y_j + \sum_{(i,j) \in R} (x_i^T y_j)^2 + \lambda (x_i, x_i) C_i = \\
 & \operatorname{argmin}_{x_i} -2x_i^T \sum_{(i,j) \in R} r_{ij} y_j + \sum_{(i,j) \in R} x_i^T y_j \cdot x_i^T y_j + \lambda (x_i, x_i) C_i = \\
 & \operatorname{argmin}_{x_i} -2x_i^T \sum_{(i,j) \in R} r_{ij} y_j + \sum_{(i,j) \in R} x_i^T y_j \cdot y_j^T x_i + \lambda C_i x_i^T x_i = \\
 & \operatorname{argmin}_{x_i} -2x_i^T \left(\sum_{(i,j) \in R} r_{ij} y_j \right) + x_i^T \left(\sum_{(i,j) \in R} y_j y_j^T + \lambda C_i \right) x_i = \\
 & \boxed{\left(\sum_{j|(i,j) \in R} y_j y_j^T + \lambda C_i I \right)^{-1} \left(\sum_{j|(i,j) \in R} r_{ij} y_j \right)}
 \end{aligned}$$

IALS (Implicit ALS)

$$p_{ij} = \begin{cases} 1, & r_{ij} > 0 \\ 0, & r_{ij} \leq 0 \text{ or } r_{ij} - \text{undefined} \end{cases}$$

Понравилось ли?

$$c_{ij} = 1 + \alpha |r_{ij}|$$

Насколько уверены в p_{ij}

$$\min_{X,Y} \sum_{\forall i,j} c_{ij} (p_{ij} - x_i^T y_j)^2 + \lambda \sum_i \|x_i\|^2 C_i + \lambda \sum_j \|y_j\|^2 C_j$$

$$C_i = \frac{(\sum_{j|(i,j) \in R} c_{ij})^\alpha |\{i\}|}{\sum_i (\sum_{j|(i,j) \in R} c_{ij})^\alpha}$$

IALS (Implicit ALS)

$$\begin{aligned}
 \operatorname{argmin}_{x_i} \sum_{\forall i,j} c_{ij} (p_{ij} - x_i^T y_j)^2 + \lambda \sum_i \|x_i\|^2 C_i + \lambda \sum_j \|y_j\|^2 C_j = \\
 \left(\sum_{\forall j} c_{ij} y_j y_j^T + \lambda C_i I \right)^{-1} \left(\sum_{\forall j} c_{ij} p_{ij} y_j \right) = \\
 \left(\sum_{\forall j | p_{ij}=0} c_{ij} y_j \cdot y_j^T + \sum_{\forall j | p_{ij} \neq 0} c_{ij} y_j y_j^T + \lambda C_i I \right)^{-1} \left(\sum_{\forall j | p_{ij} \neq 0} c_{ij} p_{ij} y_j \right) = \\
 \left(\sum_{\forall j} y_j \cdot y_j^T - \sum_{\forall j | p_{ij} \neq 0} y_j \cdot y_j^T + \sum_{\forall j | p_{ij} \neq 0} c_{ij} y_j y_j^T + \lambda C_i I \right)^{-1} \left(\sum_{\forall j | p_{ij} \neq 0} c_{ij} p_{ij} y_j \right) = \\
 \left(Y^T Y + \lambda C_i I + \sum_{\forall j | p_{ij} \neq 0} (c_{ij} - 1) y_j y_j^T \right)^{-1} \left(\sum_{\forall j | p_{ij} \neq 0} c_{ij} p_{ij} y_j \right)
 \end{aligned}$$